

Gemma 4 und Ollama

Gemma 4 ist ein Open-Source-KI-Modell der nächsten Generation von Google. Es wurde am 2. April 2026 veröffentlicht und basiert auf der Technologie von Gemini 3. Gemma 4 ist unter der **Apache 2.0-Lizenz** verfügbar, was es für kommerzielle Nutzung geeignet macht.  Xinhua +3

Hier ist eine detaillierte Anleitung zur Installation, zum Training und zur Anwendung:

1. Installation: So bringen Sie Gemma 4 zum Laufen

Es gibt vier Modellgrößen: **E2B** und **E4B** für Mobilgeräte/Edge sowie **26B (Mixture of Experts)** und **31B (Dense)** für Workstations.  Wikipedia +1

- **Lokale Installation (Einfachste Methode):**

Tools wie [Ollama](#) oder [LM Studio](#) können verwendet werden. Nach der Installation kann das Modell über das Terminal mit `ollama run gemma4` (für die Standardversion) oder spezifischen Tags wie `gemma4:31b` geladen werden.

- **Für Entwickler (Python/Hugging Face):**

Installieren Sie die Bibliotheken `transformers` und `accelerate`. Die Gewichte können direkt von [Hugging Face](#) geladen werden.

python

```
from transformers import AutoTokenizer, AutoModelForCausalLM
tokenizer = AutoTokenizer.from_pretrained("google/gemma-4-31b-it")
model = AutoModelForCausalLM.from_pretrained("google/gemma-4-31b-it", device_n
```

Verwende Code mit Vorsicht.



- **Hardware-Anforderungen:** Die kleinen Modelle (E2B/E4B) laufen auf Smartphones oder einem [Raspberry Pi](#). Die 31B-Variante benötigt idealerweise eine GPU mit mindestens **24GB VRAM** (z. B. NVIDIA RTX 3090/4090) oder eine starke CPU mit viel RAM.  Analytics Vidhya +2

2. Training: Feinabstimmung (Fine-Tuning)

Gemma 4 unterstützt **Full Fine-Tuning** sowie effiziente Methoden wie **LoRA/QLoRA**, um das Modell an spezifische Aufgaben anzupassen.  Google DeepMind +1

- **Frameworks:** Nutzen Sie [KerasNLP](#) oder [PyTorch](#). Google bietet optimierte Pipelines für [Google Cloud TPUs](#) und NVIDIA GPUs an.
- **Datenvorbereitung:** Gemma 4 ist nativ **multimodal** und kann nicht nur mit Text, sondern auch mit Bildern und Audio (bei E2B/E4B) trainiert werden.
- **Tool-Tipp:** Für eine einfache Anpassung ohne tiefes Coding eignet sich [Axolotl](#), das Konfigurationsdateien für Gemma 4 unterstützt.  Hugging Face +2

3. Anwendung: Praktische Nutzung

Gemma 4 ist für **"Agentic Workflows"** (autonome Agenten) optimiert.  [blog.google](#)

- **Thinking Mode:** Das Modell verfügt über einen integrierten "Reasoning"-Modus für komplexe Logikaufgaben.
- **Multimodalität:** Bilder, Dokumente (PDFs) oder kurze Videos (bis zu 60s) können analysiert werden. Die kleinen Modelle verarbeiten zudem direkt Audiosignale (Spracherkennung).
- **Function Calling:** Gemma 4 kann verwendet werden, um APIs zu steuern oder Tools zu bedienen (z. B. "Suche in meinem Kalender und buche einen Termin").
- **Kontext:** Mit einem Fenster von bis zu **256K Token** (bei den großen Modellen) können ganze Bücher oder umfangreiche Code-Dateien in einem Prompt verarbeitet werden.  Google AI for Developers +4

Der Start mit **Ollama** ist der einfachste Weg, um Modelle wie **Gemma 4** lokal zu betreiben, da es die gesamte Infrastruktur im Hintergrund automatisiert.  YouTube +1

Hier ist der schnellste Weg von der Installation bis zum ersten Chat:

1. Installation

Gehen Sie auf die offizielle Webseite ollama.com und laden Sie den Installer für Ihr Betriebssystem herunter:  centron GmbH +1

- **Windows:** Laden Sie die `.exe` -Datei herunter und führen Sie sie aus.
- **macOS:** Laden Sie das `.zip` -Archiv, entpacken Sie es und ziehen Sie die Ollama-App in Ihren **Programme-Ordner**.
- **Linux:** Nutzen Sie den offiziellen Befehl im Terminal: `curl -fsSL https://ollama.com/install.sh | sh`.  YouTube +5

2. Das erste Modell laden (Gemma 4)

Sobald Ollama läuft (erkennbar am Icon in der Taskleiste oder Menüleiste), öffnen Sie Ihr **Terminal** (macOS/Linux) oder die **PowerShell** (Windows) und geben Sie folgenden Befehl ein, um die Standard-Version von Gemma 4 (ca. 9,6 GB) zu laden:  YouTube +1

```
bash
```

```
ollama run gemma4
```

Verwende Code mit Vorsicht.



Ollama lädt das Modell nun automatisch herunter. Sobald der Fortschrittsbalken 100 % erreicht hat, öffnet sich direkt ein Chat-Interface im Terminal. 

3. Wichtige Befehle zur Steuerung

Sie können Ollama komplett über das Terminal verwalten: 

- `/bye` : Beendet den aktuellen Chat.
- `ollama list` : Zeigt alle Modelle an, die Sie bereits heruntergeladen haben.
- `ollama rm <modellname>` : Löscht ein Modell, um Speicherplatz freizugeben.
- `ollama pull gemma4:31b` : Lädt die große 31B-Variante herunter, ohne den Chat sofort zu starten.  YouTube +3

4. Den richtigen "Flavor" wählen

Je nach Ihrer Hardware können Sie spezifische Versionen von Gemma 4 wählen:  Ollama +3

- **gemma4:e2b** (ca. 7,2 GB): Optimiert für Geräte mit wenig RAM (z. B. Laptops mit 8 GB).
- **gemma4:e4b** (ca. 9,6 GB): Die Standard-Balance zwischen Speed und Intelligenz.
- **gemma4:31b** (ca. 20 GB): Für komplexe Aufgaben, benötigt idealerweise 24 GB VRAM oder viel Systemspeicher.  YouTube +4

Pro-Tipp: Wenn Ihnen das Terminal zu unübersichtlich ist, können Sie Tools wie das [Open WebUI](#) (ehemals Ollama WebUI) installieren, um eine Oberfläche wie bei ChatGPT zu erhalten.  YouTube +1

Möchten Sie wissen, wie Sie Ollama direkt in andere Programme wie **VS Code** oder **Obsidian** integrieren können?