

Hier ist die managementtaugliche Zusammenfassung für die geplante Bereitstellung im Haus.

Executive Summary: Lokale KI-Infrastruktur mit Ollama und Gemma 4

Die geplante On-Premises-Installation von **Ollama** als Server-Dienst und **Gemma 4** (Googles neuester Open-Source-Modellfamilie unter [Apache 2.0-Lizenz](#)) auf einem **In-House Windows-Server** ermöglicht dem Unternehmen die datenschutzkonforme Nutzung hochmoderner künstlicher Intelligenz (Text- und Bildverarbeitung). Alle Daten verbleiben vollständig im lokalen Netzwerk (LAN); es erfolgt **kein Datenabfluss an externe Cloud-Anbieter**.  YouTube - Google for Developers +3

Key-Facts & Strategische Vorteile

- **100 % Datensouveränität:** Datenaustausch und Verarbeitung geschehen ausschließlich firmenintern (wichtig für sensible Geschäftsdaten, DSGVO und IP-Schutz).  [blog.google](#)
- **Keine laufenden Token-Kosten:** Nach der einmaligen Hardware-Anschaffung fallen keine verbrauchsabhängigen Lizenz- oder API-Gebühren an.  DEV Community +1
- **Gemma 4 Leistungsniveau:** Die Modelle basieren auf Googles Gemini 3-Forschung und gehören in ihrer Größenklasse zur weltweiten Spitzenklasse. Sie beherrschen erweitertes logisches Denken (Thinking Mode), Code-Generierung, Bildanalyse (Multimodalität) sowie komplexe Agenten-Workflows.  Google AI for Developers +4
- **Zentralisierte Bereitstellung:** Ollama fungiert als Server-Kern. Mitarbeiter oder interne Software greifen über standardisierte Schnittstellen (REST-API) im lokalen Netz darauf zu.  Ollama +2

Modell-Optionen & Hardware-Auslegung (Inferenz)

Gemma 4 bietet verschiedene Modellgrößen. Für einen Serverbetrieb stehen die **Workstation-/Server-Modelle** im Fokus, die je nach Qualitätsanspruch und Hardware-Budget gewählt werden: [Google AI for Developers +2](#)

Modellvariante 	Empfohlener Einsatzzweck	VRAM-Bedarf (4-Bit quantisiert)	VRAM-Bedarf (Umfassend / unquantisiert)
Gemma 4 (26B A4B MoE)	Geschwindigkeit & Durchsatz (Aktiviert nur 3,8B Parameter pro Token; ideal bei vielen parallelen Anfragen)	~15,6 GB	~48 GB (BF16)
Gemma 4 (31B Dense)	Maximale Qualität & Logik (Beste Ergebnisse für komplexe Analysen und Programmierung)	~17,4 GB	~58,3 GB (BF16)

Hinweis zu den kleinen Modellen (E2B / E4B): Diese sind primär für Smartphones/Edge-Geräte optimiert und im lokalen Netz meist unterfordert. [Google AI for Developers +1](#)

Hardware-Empfehlung für den Windows-Server:

Um eine flüssige Generierungsgeschwindigkeit (Tokens pro Sekunde) im Mehrbenutzerbetrieb zu gewährleisten, sollte der Server mit **dedizierten NVIDIA-Grafikkarten** (z. B. 1x oder 2x RTX 6000 Ada, alternativ günstige Consumer-Karten wie RTX 4090/5090 mit ausreichend Videospeicher) ausgestattet werden. Die Ausführung rein über die Server-CPU ist technisch möglich, für den produktiven Betrieb im Team jedoch zu langsam. [Google AI for Developers +2](#)

Technische Umsetzung auf Windows Server

Die Bereitstellung erfolgt in wenigen Schritten und lässt sich einfach in die bestehende IT-Infrastruktur integrieren:

1. **System-Vorbereitung:** Installation der aktuellen NVIDIA-Grafikkartentreiber auf dem Windows Server.  Ollama
 2. **Ollama-Installation:**
 1. Für den echten Server-Dienst wird das offizielle [Ollama-ZIP-Paket für Windows CLI](#) heruntergeladen.
 2. Die Einbindung als dauerhafter Windows-Systemdienst (Start bei Boot ohne Benutzeranmeldung) erfolgt am saubersten über Tools wie **NSSM** (Non-Sucking Service Manager).  Ollama
 3. **Konfiguration für das lokale Netzwerk:**
 1. Standardmäßig blockiert Ollama externe Zugriffe (`localhost`).
 2. Über die Windows-Systemumgebungsvariablen muss Folgendes gesetzt werden:
 - `OLLAMA_HOST = 0.0.0.0` (Gibt den Server für das gesamte lokale Netz frei).
 - `OLLAMA_MODELS = D:\OllamaModels` (Verschiebt den Speicherort der KI-Modelle weg von der meist kleinen System-SSD).  Ollama +4
 4. **Modell-Download:** Über den Server-Befehl `ollama run gemma4:31b` (oder `:26b`) lädt der Server das Modell einmalig verschlüsselt herunter.  Ollama +1
 5. **Netzwerk-Sicherheit:** In der Windows-Firewall des Servers muss der **Port 11434** für eingehende Verbindungen aus dem internen Firmennetzwerk freigegeben werden.  Ollama +1
-

Benutzeroberfläche (Frontend) für Mitarbeiter

Da Ollama im Hintergrund als reiner API-Dienst läuft, wird für die Endanwender eine grafische Oberfläche benötigt. Hierzu empfiehlt sich die Installation einer Open-Source-Oberfläche (z. B. **Open WebUI**). Diese wird zentral auf dem Server (z. B. via Docker) oder einem IIS-Webserver bereitgestellt.  Ollama +2

Mitarbeiter rufen die KI anschließend einfach im Browser über eine interne Adresse (z. B. `http://firma.local`) auf – ähnlich der Nutzung von ChatGPT, aber vollständig intern.  Unsloth

Möchten Sie als nächsten Schritt eine konkrete **Hardware-Einkaufsliste** für den Server abstimmen, oder benötigen Sie Unterstützung bei der Auswahl einer passenden **Benutzeroberfläche (Frontend)** für die Mitarbeiter?